

Estudio de Aplicación de Metaheurísticas al problema Maximum Diversity Problem (MDP)

Cristian Medina

Manuel Pacheco

Abstract

El problema de máxima diversidad (Maximum Diversity Problem), consiste en elegir M elementos de un conjunto de N elementos tal que la suma de las distancias entre los elementos elegidos sea la máxima posible. Catalogado como un problema NP-Hard en 1993 por Kou, Glover y Dhiti, el problema está formalmente estipulado bajo la siguiente fórmula de función objetivo a maximizar y restricción de tamaño:

$$\sum_{i=1}^{n-1} \sum_{j=i+1}^n d_{ij} x_i x_j$$

$$\sum_{i=1}^n x_i < m$$

Donde n es la cardinalidad de elementos del conjunto, m la cantidad de elementos elegidos, d_{ij} es la distancia entre el elemento i y el elemento j , x_i es una función booleana que toma el valor de 1 si el elemento i fue elegido, 0 si no fue elegido. Estas definiciones son las utilizadas en menciones posteriores en caso de omitirse una definición en el momento.

Las aplicaciones de este problema se pueden encontrar en estudios genéticos, sistemas ecológicos, controles de inmigración, tratamientos médicos, entre otros. Ha sido un caso de estudio para la aplicación de heurísticas y metaheurísticas, particularmente para la búsqueda local. Fue catalogado como un problema NP-Hard en 1993 por Kou, Glover y Dhiti al reducir el problema de clique a MDP.

El presente artículo presenta un estudio sencillo de la aplicación de metaheurísticas para la resolución de este problema. Se realiza un estudio comparativo de las técnicas de Local Search (LS), Iterated Local Search (ILS), Tabu Search (TS), Genetic Algorithm (GA) y Scatter Search (SS) en las instancias del problema en los sets SOM, GKD y MDG de MDPLIB de opticom.es.

1. Trabajos Previos

El problema de máxima diversidad ha sido estudiado aplicando múltiples heurísticas y metaheurísticas. En general todas las heurísticas estudiadas presentan buenos resultados, sin embargo, se destacan las de búsqueda local al poseer resultados de mejor calidad para la mayor parte de los casos de prueba.

Se destaca en particular el Basic VNS por Brimberg [1]. Este consiste en una estructura de datos eficiente que representa los conjuntos de datos actualizados, del cual genera aleatoriamente una solución parcial a la cual le aplica una búsqueda local intercambiando los elementos de su solución con los elementos no incluidos. En un segundo lugar, se encuentra el VNS implementado por Aringhieri y Cordone [2], el cual consiste en una construcción de una solución con un método greedy y un posterior procesamiento cambiando k elementos de la solución y aplicando una búsqueda tabú simple sobre esta.

Para casos de prueba de mayor tamaño, se destaca las búsquedas en Tabú. Un ejemplo de esta es la presentada por Palubeckis [5], una búsqueda Tabú iterativa que alterna entre búsqueda tabú y técnicas de perturbación. Cuando la búsqueda Tabú encuentra un resultado mejor al inicial, utiliza una búsqueda local a la nueva solución. Su método de perturbación es una selección de elementos aleatorios del conjunto para viajar por el espacio de soluciones. Para casos pequeños este método se desempeña bien, pero no es el mejor.

Cabe destacar también las estrategias GRASP desarrolladas por Silva et al [3], donde se construye una solución parcial inicial y se mejora de forma iterativa; y la propuesta por Duarte y Martí [4], que parten de la heurística propuesta por Glover de C2 y D2, aplicándole su propia metodología GRASP.

2. Representación de la solución

Para la representación de una solución del problema se utilizan dos alternativas. Para los algoritmos LS, ILS,

TS y SS se optó por una representación compacta. Sea el conjunto de elementos de tamaño n y la solución de tamaño m , se opta por representar la solución como un vector de tamaño m donde cada componente contiene la etiqueta del elemento escogido. Para GA se utiliza una representación completa: un vector de tamaño n donde cada componente está permanentemente asociada a un elemento del problema e indica si pertenece o no a la solución (i.e. un x_i como en la descripción del problema).

3. Solución Inicial

Dependiendo de la metaheurística a utilizar se usan métodos de construcción de las soluciones iniciales de forma diferente. La primera es la clásica solución aleatoria: se seleccionan los elementos que pertenecen a la solución al azar. La segunda sigue un principio de intuición que denominamos Potencial de un elemento definida de la siguiente forma:

$$P(i) = \sum_{j=1}^n d_{ij}$$

De manera informal, el Potencial de un elemento indica cuánto aporta a la función objetivo si se tomasen en cuenta todas las conexiones con todos los demás elementos. Por tanto, elegimos los primeros m nodos que tengan mayor potencial. Definimos a esta estrategia como solución inicial greedy.

En la mayoría de los problemas trabajados, las soluciones aleatorias rondan generalmente entre 50 % y 75 % del valor de las mejores soluciones encontradas en la librería (soluciones referencia), dependiendo del tamaño del problema, siendo las peores los de problemas más grandes. La solución greedy supera el 95 % y tiende a llegar tan alto como 98 % de la solución referencia.

En la mayoría de los problemas se intenta utilizar la solución greedy sobre la aleatoria. Para LS, ILS y TS se utiliza greedy. Para las metaheurísticas poblacionales GA y SS, se inicia con soluciones aleatorias.

4. Local Search

hey

4.1. Inicio

hola

5. Local Search

En la implementación de búsqueda local se decide por

```

1  $V \leftarrow$  vector de arcos
2  $S \leftarrow$  vector solución inicial
3  $C \leftarrow$  vector de elementos no elegidos
4  $IS \leftarrow \emptyset$  // conjunto de cambios probados
5  $Itera \leftarrow true$  // cota de salida
6  $localIter \leftarrow 0$ 
7  $totalIter \leftarrow 0$ 
8  $pivote \leftarrow |S| - 1$ 
9  $distanciaActual = Distancia(S)$ 
10 while  $true$  do
11   if  $localIter < MAX\_LOCAL\_LITER \wedge$ 
      $localIter < |Nodos| - |S|$  then
12      $NodoAleatorio \leftarrow Rand(C)$ 
13     if  $NodoAleatorio \in IS$  then
14       continue
15      $IS \leftarrow IS \cup \{NodoAleatorio\}$ 
16      $respaldo \leftarrow pivote$ 
17      $pivote \leftarrow nodoAleatorio$ 
18     if  $Distancia(S) > distanciaActual$  then
19        $DistanciaActual = Distancia(S)$ 
20        $C = C - nodoAleatorio + respaldo$ 
21     else
22        $pivote = Respaldo$ 
23      $localIter ++$ 
24      $totalIter ++$ 
25   else
26      $IS \leftarrow \emptyset$ 
27      $localIter = 0$ 
28      $pivote --$ 
29   if  $totalIter > MAX\_ITER \vee pivote < 0$  then
30     return  $distanciaActual$ 
```

6. Búsqueda ILS

En la implementación de la metaheurística de búsqueda local iterativa, a partir de una solución inicial, comienza un ciclo de donde se perturba la mejor solución, se mejora esa solución parcial y se comparan las soluciones. La perturbación consiste en intercambiar aleatoriamente k nodos de la solución parcial por nodos no elegidos. El mejoramiento es realizar una búsqueda local a la solución obtenida por la perturbación. Luego se compara la solución parcial con la mejor solución obtenida, y se actualiza la segundar de ser mejor la solución parcial.

Si transcurren h ciclos sin que mejore la solución, se procede a aumentar la perturbación, aumentando en uno el k . Este ciclo ocurre hasta que se cumpla un número máximo de iteraciones, o el valor k de las perturbaciones supera el tamaño de la solución.

7. Resultados

Para el estudio del desempeño de los algoritmos, se ejecuto 15 veces cada caso de prueba y se promediaron los datos obtenidos. Se consideran los casos de prueba GDK-c que consisten en puntos generados aleatorios y sus respectivas distancias euclidianas entre si, con una cantidad de nodos igual a 500 y una solución de tamaño 50. También se consideran 5 casos de SOM-b, con una cantidad de nodos entre 100 y 200, soluciones de tamaño 10 a 40, que consisten en arcos generados aleatoriamente, extraídos de una distribución uniforme. Igualmente se usan los casos de MDG-a, que son arcos enteros entre 0 y 10 sacados aleatoriamente de una distribución uniforme, con problemas con 500 nodos y 50 de tamaño de soluciones, y sus 3 de sus versiones más grandes de 2000 nodos y 200 de tamaño de solución

En general los resultados dados con ILS superan en calidad a los presentado solo con Búsqueda Local. Esto ocurre tanto con soluciones iniciales aleatorias como con soluciones iniciales con el procesamiento greedy antes descrito. Sin embargo su costo de tiempo es considerablemente mayor. En particular con los casos más grandes, MDG-a de 2000 nodos, ILS llega a tardar 10 minutos a diferencia d LS que tarda poco más de un segundo, con una diferencia de 2 por las corridas con la solución inicial greedy obtienen mejores resultados que con soluciones iniciales aleatorias.

Referencias

- [1] Brimberg, J., N. Mladenovic, D. Urošević and E. Ngai. (2009). Variable neighborhood search for the heaviest k -subgraph. *Computers & Operations Research*, 36(11): 2885-2891.
- [2] R. Aringhieri and R. Cordone. Better and faster solutions for the maximum diversity problem. *Technical report, Universit degli Studi di Milano, Polo Didattico e di Ricerca di Crema*, 2006.
- [3] G.C. Silva, M.R.Q. Andrade, L.S. Ochi, S.L. Martins, and A. Plastino. New heuristics for the maximum diversity problem. *Journal of Heuristics*, 13(4):315–336, 2007.
- [4] R. Aringhieri, R. Cordone, and Y. Melzani. Tabu search vs. grasp for the maximum diversity problem. *A Quarterly Journal of Operations Research*, 6(1):45–60, 2008.
- [5] G. Palubeckis. Iterated tabu search for the maximum diversity problem. *Applied Mathematics and Computation*, 189:371383, 2007.